

SAIR FOUNDATION 主旨演讲 · 视觉文档

加州理工学院数学物理学家 谈 AI 的“最难题”

稀疏奖励与长时程：从 Ramsey 数到 Andrews–Curtis 猜想

演讲者：Sergei Gukov（加州理工学院 数学物理教授）

原视频：bilibili BV13T3x69Eqz（约 35 分钟，英文演讲）

本文档：语音识别转写 · 中文译稿 · 幻灯片画面

整理日期：2026 年 8 月 10 日

使用说明

本文档由 B 站视频《加州理工学院数学物理学家谈 AI 的“最难题”》（BV13T3x69Eqz，UP 主：SAIRfoundation）自动整理而成。整理流程为：下载视频 → 提取音频并做英文语音识别（Whisper）→ 按幻灯片翻页时间对齐转写文本 → 翻译为中文 → 与幻灯片截图合成视觉文档。

正文共 25 节，每节对应演讲中的一页幻灯片，包含：

- （1）该页幻灯片的画面截图及其出现的视频时间段；
- （2）演讲者在该页停留期间所讲内容的**中文译稿**（忠实于口语原意，保留关键技术名词的英文原文）。

两点提示：其一，演讲为即兴口语，语音识别难免存在个别词句误差，译稿在不改变原意的前提下做了通顺化处理；其二，演讲者 Sergei Gukov 是加州理工学院数学物理教授，研究方向为纽结理论、拓扑量子场论，近七年转向 AI 基础研究，主持 Caltech Math+AI 实验室——本场演讲正是他站在数学家视角，对强化学习中“稀疏奖励 + 长时程”这一核心难题的系统性阐述。



All models are wrong but some are useful.
George Box, 1979



I have not failed. I've just found 10,000
ways that won't work.
Thomas Edison



I see only one move ahead, but always the best move.
Charles Jaffe, Chess Review, May 1946



幻灯片 1：三则引言——George Box“所有模型都是错的，但有些是有用的”；爱迪生“我没有失败，我只是找到了一万种行不通的方法”；Charles Jaffe“我只看一步，但总是最好的一步”。

.....所以此刻我感觉像是转了一个完整的圈（full circle）。今天我要讲的是 AI 面临的一些挑战，以及我自己是如何走进这个领域的。这场演讲会高度聚焦——聚焦在设计更好的 AI 系统时，两个相辅相成、形影不离的瓶颈。第一个，就是稀疏奖励（sparse reward）问题。


- **Sparse reward:** The signal is often only a final state — “pass / fail,” “found / not found,” or “synthesized / not synthesized.”
- **Long horizon:** Dozens to thousands of actions must align before success is visible.

$0.99^{100} \approx 37\%$
100 actions with independent per-step reliability

$0.995^{100} \approx 61\%$
100 actions with independent per-step reliability

$0.999^{100} \approx 90\%$
100 actions with independent per-step reliability

- The agent must preserve goals, hidden state, constraints, and recovery plans over time.
- Popular applications: code repair, web/office work, robots, autonomous labs, games, and algorithm discovery.
- The key question is no longer “can it answer?” but “can it steer a process until the reward appears?”




幻灯片 2：稀疏奖励——信号往往只在终点出现（“通过/未通过”“找到/没找到”“合成成功/失败”）；长时程——数十到数千步动作必须在成功显现之前保持对齐。 $0.99^{100} \approx 37\%$ ， $0.995^{100} \approx 61\%$ ， $0.999^{100} \approx 90\%$ 。

设想你要把 AI 应用到这样一类任务上：在成百上千万乃至数十亿条轨迹中，只有一条有意义的轨迹值得你付出努力。第二个挑战是：这条轨迹还异常地长。这两个问题各自单独出现时就已经够麻烦了，但更多时候它们叠加在一起——一旦叠加，情况就“有意思”了。

长时程（long horizon）的问题很好理解。假设你要连续完成 100 步关键操作，每一步的错误率只有 1%——听起来相当不错；但当你必须连走 100 步时，就没那么好了（ $0.99^{100} \approx 37\%$ ）。再想象一下，如果是几千步、甚至上百万步关键操作呢？

就在上个周末，我在纽瓦克参加了一个 AI 峰会，有两位演讲者分别介绍“用 AI 设计飞机”和“用 AI 设计聚变反应堆”。这两个问题的目标看起来完全不同，但恰恰都属于这个范畴。以聚变反应堆为例，它是典型的稀疏奖励问题——我们手上并没有一个已经正常运转、令人满意的聚变反应堆，这是要从零发明的设计。飞机也一样：AI 被用来设计飞机，当然也可以用来驾驶飞机——而这又是一项有无数关键环节必须完美协同的任务：你登上飞机，就要确信它能安全落地。这个例子同时体现了稀疏奖励与长时程：一方面步骤极多；另一方面奖励稀疏——AI 设计出的候选飞机总得实际测试，可你能造出来几架？也许 300 架、也许 3000 架，但这永远达不到典型数据科学任务所需的数据集规模。

这类“稀疏奖励 + 长时程”的挑战出现在许多领域：编程、机器人与自动驾驶、游戏（游戏其实是非常有用的一课），以及算法发现。在这些任务里，问题已经不再是“AI 能不能找到解”——答案很简单：不能，至少在稀疏奖励的探索中是如此。真正的问题变成了：你该如何引导（steer）整个过程，让它朝正确的方向走？比如设计聚变反应堆——你该如何奖励它，让它走到正确的位置？



幻灯片 3：编程智能体仍然失败得早、失败得无声、失败得昂贵；长时程失败往往是“诊断失败”；记忆与技能创造时间抽象（Voyager 在 Minecraft 中的课程学习 + 可执行技能库 + 自我验证）。

以编程智能体（coding agents）为例，这个领域已经取得了很大成功——如果你自己写代码、或者用 AI 辅助写代码，大概深有体会，它们正在变得越来越好。但长时程任务仍然带来巨大挑战。比如有一类编程难题：要在一个包含大量文件的大型代码仓库里找出一个 bug。智能体必须翻遍大量文件、定位出错的确切位置，而奖励只有“是/否”——bug 修没修好，它是之前许许多多步操作的函数。

过去真正起作用的，是某种形式的记忆（memory），以及“技能”（skills）——把某些行为模式或正确的应对场景吸收进来，打包成可以当作单步调用的例程。很高兴今天能和之前的一位演讲者 Anima 同校，她在这方面的贡献包括部署这类系统，进而发展出世界模型（world models）等工具，把探索任务和步骤组合成类似“技能”的东西。

- Real-world caveat: skills become stale when tools, repositories, robots, or lab protocols change.
- Robotics makes long horizons and sparse rewards physical: every failed step can cost time, hardware, or safety margin.



- The bottlenecks are physical: slow experiments, ambiguous measurements, limited action spaces, and safety constraints.

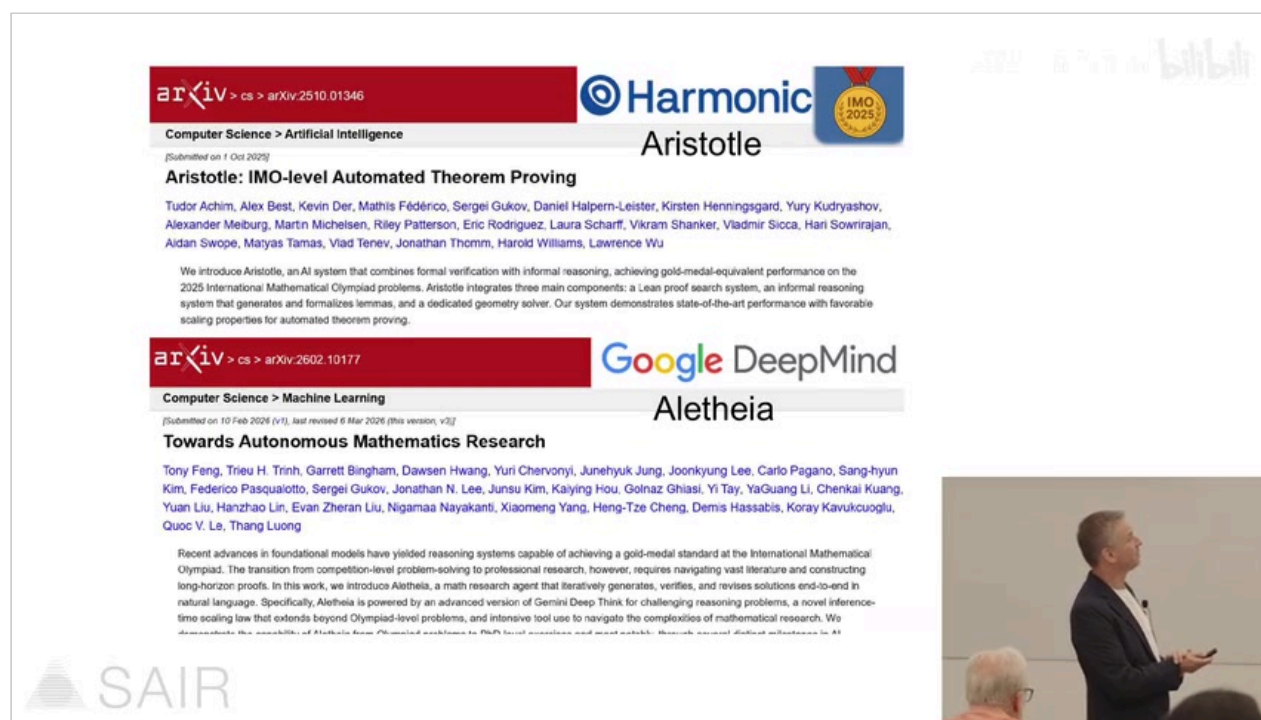


幻灯片 4：真实世界的警示——工具、代码库、机器人、实验流程一变，技能就过时；机器人让长时程与稀疏奖励变成“物理的”：每一步失败都消耗时间、硬件与安全余量；瓶颈是物理层面的：实验慢、测量含混、动作空间有限、安全约束。

但这条路即便在一定程度上有效，挑战依然存在。一些编程类基准测试目前只解决了大约 25%，稀疏奖励和长时程任务上还有不少硬骨头。

而在物理 AI（physical AI）领域，事情变得更棘手。以机器人为例——前面几场演讲已经多次提到——你希望快速拿到反馈信号，但“快”本身、以及能拿到多少信号，就已经是挑战。其次，真实世界里一切都是模糊的，有时连采集测量的方式本身就含混不清。正因如此，我们现在还没有能给你做一顿晚餐的机器人：机械手可能有点对不准、有点抖，而这些微小误差会迅速累积；在物理世界里情况只会越来越糟，再叠加其他必须极其精密才能奏效的技术环节，难度可想而知。

我个人对 AI 实验室（AI labs）非常期待：一旦我们能把“机器人 + 高质量反馈 + 自动化 + 高速迭代”这个闭环合上，就有望在几乎没有人类参与的情况下做真正的科学实验。但坦率说，我们离那一天还很远——稀疏奖励与长时程正是其中的关键。当然，还有自动驾驶等许多其他领域，我就不一一展开了。



arXiv > cs > arXiv:2510.01346

Computer Science > Artificial Intelligence

[Submitted on 1 Oct 2025]

Aristotle: IMO-level Automated Theorem Proving

Tudor Achim, Alex Best, Kevin Der, Mathis Fédérico, Sergei Gukov, Daniel Halpern-Leister, Kirsten Henningsgard, Yuri Kudryashov, Alexander Meiburg, Martin Michelsen, Riley Patterson, Eric Rodriguez, Laura Scharff, Vikram Shanker, Vladimir Sicca, Hari Sowrirajan, Aidan Swope, Mayyas Tamas, Viad Tenev, Jonathan Thomm, Harold Williams, Lawrence Wu

We introduce Aristotle, an AI system that combines formal verification with informal reasoning, achieving gold-medal-equivalent performance on the 2025 International Mathematical Olympiad problems. Aristotle integrates three main components: a Lean proof search system, an informal reasoning system that generates and formalizes lemmas, and a dedicated geometry solver. Our system demonstrates state-of-the-art performance with favorable scaling properties for automated theorem proving.

arXiv > cs > arXiv:2602.10177

Computer Science > Machine Learning

[Submitted on 10 Feb 2026 (v1), last revised 6 Mar 2026 (this version, v3)]

Aletheia

Towards Autonomous Mathematics Research


Tony Feng, Trieu H. Trinh, Garrett Bingham, Dawson Hwang, Yuri Chervonyi, Junehyuk Jung, Joonkyung Lee, Carlo Pagano, Sang-hyun Kim, Federico Pasqualotto, Sergei Gukov, Jonathan N. Lee, Junsu Kim, Kaiying Hou, Golnaz Ghiasi, Yi Tay, YaGuang Li, Chenkai Kuang, Yuan Liu, Hanzhao Lin, Evan Zheran Liu, Nigamaa Nayakanti, Xiaomeng Yang, Heng-Tze Cheng, Demis Hassabis, Koray Kavukcuoglu, Quoc V. Le, Thang Luong

Recent advances in foundational models have yielded reasoning systems capable of achieving a gold-medal standard at the International Mathematical Olympiad. The transition from competition-level problem-solving to professional research, however, requires navigating vast literature and constructing long-horizon proofs. In this work, we introduce Aletheia, a math research agent that iteratively generates, verifies, and revises solutions end-to-end in natural language. Specifically, Aletheia is powered by an advanced version of Gemini Deep Think for challenging reasoning problems, a novel inference-time scaling law that extends beyond Olympiad-level problems, and intensive tool use to navigate the complexities of mathematical research. We demonstrate the feasibility of Aletheia from Olympiad problems to deep-level research and open-ended research across distinct subdomains in AI.

SAIR

幻灯片 5: Harmonic 公司的 Aristotle (IMO 级别自动定理证明) 与 Google DeepMind 的 Aletheia (迈向自主数学研究) 两篇论文。

为什么讲这些? 大约七年前, 我把研究方向从当时的量子拓扑 (quantum topology) ——一个相当深奥的数学分支——转向了 AI 研究。此后我有幸参与了若干项目, 其中一些是与 AI 公司合作的: 比如我和 Alex 等人合作的模型 Aristotle, 以及更近期与 Google DeepMind 合作的 Aletheia。不知为什么, 这些初创团队和公司都喜欢让模型的名字以字母 A 开头……



幻灯片 6：Caltech Math+AI 团队主页——致力于攻克需要长时程推理、稀疏奖励、算法发现与科学发现的 AI 系统。

.....原因就留给大家猜了。在我所在的加州理工学院，我主持一个 Math+AI 实验室，专注于数学推理。如果你去读实验室的介绍，最后一句话就会点明：我们极度专注于稀疏奖励、长时程任务——设计新的算法、新的架构来攻克这些挑战。其他的我们都不关心，只关心长时程稀疏奖励，仅此而已。这对数学很重要，而今天这场演讲的目的就是解释为什么、以及怎么做。

还有一点：实验室创立时我们有一句口号——“数学 + AI = AGI”。那是五年前。放到今天，我大概得把它改成“数学 + AI = ASI（人工超级智能）”了。为什么？因为实现这种探索能力、实现分布外（out-of-distribution）泛化，恰恰是 AGI、甚至超级智能所需要的——要能在“盒子之外”进行推理。

Mathematical problems range in complexity and difficulty:


- elementary school problems
- middle school problems
- high school problems
- math olympiad problems; e.g. International Mathematical Olympiad (IMO)
- undergraduate-level problems general purpose tool
- graduate-level problems
- simple research problems that mathematicians solve as part of their daily routine
- research problems whose solutions become the main results of research papers published in leading mathematical journals
- Long-standing problems open for decades (AC, ...)
- Millennium Prize Problems



幻灯片 7：数学问题的复杂度与难度谱系——从小学、中学、奥数（IMO）、本科、研究生，到职业数学家的日常研究问题、顶级期刊论文、数十年悬案（如 AC 猜想）、千禧年大奖难题。

说到数学，必须一开始就澄清：数学有不同的类型和难度层级——从小学、中学、高中数学，到数学竞赛（如 IMO），再到本科、研究生阶段的数学，层层递进。通用的 LLM 工具在这套层级上推进得相当快，大致每年上一个台阶。接下来的问题是：这种势头会持续吗？能走多远？老实说，我不知道。但未来很值得关注，两种可能都可以设想。


比如我画的那条绿线，就是我希望 AI 能到达的位置——那是最难的一层数学，包含我的学生们遇到的最难的问题，许多职业数学家倾尽全力也解不出来，往往需要许多年和杰出的头脑才能触及。我个人希望看到 AI 走到那一步。但挑战之一是：这类问题我们几乎没有训练数据。以黎曼猜想（Riemann hypothesis）为例——市面上有很多“看起来很像样”的论文，很不幸我读过，里面有各种各样的错误；但正确解一个都没有。因此没有任何可以训练的东西。这个问题和设计聚变反应堆一模一样：我们连一条数据都没有，AI 必须自己把它想出来。



幻灯片 8：人类数学家与机器人相对而坐——10X、100X、1000X。

换句话说，我坚信 AI 是最好的出路。我坚信 AI 能帮助我——一个职业数学家、科学家——把研究效率提升 10 倍、100 倍、1000 倍。但我想问的是：它能不能彻底超越我，做得比我好得多？这正是我们在做的事——设计这样的算法和架构。

有意思的是，我等于是正在努力“取代”作为人类数学家的自己。自然会有人问：你为什么要这么干？老实说，我也不知道——一半是出于好奇和“恶作剧”心理。更严肃的回答，类似乔布斯当年开发图形用户界面时的故事：有人问他，“Steve，你做这件事会毁掉整个公司。”他的回答是：“与其让别人做给我们看，不如我们自己先做。”我也觉得，也许通过做这件事，我们能更好地理解这些系统究竟如何运作……




幻灯片 9：17 个顶点的完全图有 2.46×10^{26} 种染色；Ramsey 数 $R(r, s)$ 已知值与界的表格——黄色格 $R(5, 5)$ 至今未知。

.....如何保障它们的安全，以及许多其他重要问题。

那么，稀疏奖励和长时程与数学中最难的挑战有什么关系？这里有一个关于图的染色的问题，即 Ramsey 数（Ramsey numbers）的计算。这个问题很容易陈述：可以表述为一个双人游戏，两名玩家分别用红色和蓝色给图的边染色，满足特定条件者获胜。但随着图的规模稍稍变大——注意，只是平面内能画出来的那种规模，比如 5 个、18 个顶点——问题的复杂度就以组合爆炸的速度增长。要回答下一个有趣的问题，你要搜索的空间规模达到 10^{26} 量级。而这正是有趣的数学会把你带到的地方。


如何教会 AI 只凭这张 Ramsey 数表中对角线上已知的寥寥几个例子，就学会外推（extrapolate）到那么遥远的地方，对天文数字般的规模做出合理可靠的推断？这是一个悬而未决多年的难题。我记得有人这样形容它的难度：如果外星人降临地球，下最后通牒——要么我们给出下一个 Ramsey 数，要么他们毁灭人类。如果他们问的是 $R(5, 5)$ ——就是表里黄色那一格，我们目前只知道上下界、不知道精确值——那我们应该集结全人类的智慧去攻克它；但如果他们问的是 $R(6, 6)$ ，那我们还是直接投降算了。这个段子足以说明这里的复杂度有多么天文级别。



幻灯片 10：寻找大直径的“线性”单项式理想——两个条件各自容易、同时满足极难，如大海捞针（G. Butbaia 等，ICML 2026）。

接下来是一个我确实解决了的问题——另一个出自组合数学邻近领域的难题。组合数学里曾有一个著名的 Hirsch 猜想（Hirsch conjecture），大约十年前被 Santos 证否，轰动一时。后来，我的同事 David Eisenbud——曾任 MSRI（美国国家数学科学研究所）所长——来访，我们聊起来，他提出在交换代数（commutative algebra，他的领域）里存在一个类似的问题，他称之为“Hirsch 猜想的代数版本”：要在交换代数中找到同时满足两个条件的实例——其一是“大直径的单项式理想”（monomial ideal of large diameter，与原始 Hirsch 猜想非常相似的性质），其二是“线性”（linear）。这两个条件的技术细节并不重要，关键是：每个条件单独看都很容易满足——线性的、或者大直径的单项式理想都一抓一大把；但一旦要求两者同时成立，就又变成了“大海捞针”式的搜索，和刚才 Ramsey 数的情况一样。

与上一个问题不同，这一个我们真的解决了——过程绝不平凡，前后花了好几年，最终发表在 ICML 上。之所以发表在计算机科学的会议上——尽管最终成果是一个定理、一个漂亮的数学结果——是因为用 AI 去解决它，本身就需要开发大量新的 AI 方法。接下来我会带大家一窥这个过程：为攻克一个问题而发展 AI，实践中往往需要数月乃至数年的算法工作。



幻灯片 11：智能体—环境交互循环——智能体采取动作（Action），环境返回状态与奖励（State, Reward）。

这类 AI 算法的核心特征之一，就是智能体从中学习的反馈回路（feedback loop）——强化学习（RL）正是刻画这类算法如何开发、如何运转的绝佳模型。而且 RL 往往就是关键组件：无论是 LLM 的后训练（post-training）与对齐（alignment）——LLM 的稳健性很大程度上来自 RL；还是像我前面说的，把任务本身表述为一个游戏——许多数学问题天然就带有这种结构。RL 都是思考问题、切入问题的好方式：智能体与环境交互、收集奖励、改进自身行为，很多事情就是这么完成的。

那么自然要问：强化学习在这类任务上表现如何？该选什么算法？接下来十分钟，我会带大家快速领略一番。

arXiv:1312.5602v1 [cs.LG] 19 Dec 2013

Playing Atari with Deep Reinforcement Learning

Volodymyr Mnih Koray Kavukcuoglu David Silver Alex Graves Ioannis Antonoglou
Daan Wierstra Martin Riedmiller
DeepMind Technologies



Figure 1: Screen shots from five Atari 2600 Games: (Left-to-right) Pong, Breakout, Space Invaders, Seaquest, Beam Rider


In 2013, DeepMind introduced **Deep Q-Network (DQN)** algorithm to learn to play Atari games from raw pixels.

SAIR



幻灯片 12：2013 年 DeepMind 论文《Playing Atari with Deep Reinforcement Learning》——DQN 从原始像素学习玩 Atari 游戏。

在 RL 课程上，我们通常从 DQN（Deep Q-Network）讲起——它是经典 Q-learning 算法的深度网络版本。这个算法本身也有一段有趣的来历：2013 年出自 DeepMind——按 AI 的时间尺度，这已经是“远古时代”了，而它确实也是你能选的最基础的算法。当时他们做的事，在那部关于 DeepMind 的纪录片里讲得很精彩：他们试图让 AI 仅仅从像素化的屏幕画面学会玩 Atari 游戏。这是一段有趣的旅程——最初什么都不 work，他们试了好几个月，最后才拿出这个如今看来非常、非常基础的 RL 算法。它玩得相当不错——但故事还有下半段：它在大多数游戏上玩得好，……



幻灯片 13：DQN 在各 Atari 游戏上的表现分布——Montezuma's Revenge 垫底，得分恰好为零。

.....但在另一些游戏上惨败。这张分布图上是许多 Atari 游戏的名字，柱状条表示这个算法在各游戏上的表现。有一款游戏排在最底部——对我个人来说它一点也不特别，我也没怎么玩过 Atari——它叫 Montezuma's Revenge（蒙特祖玛的复仇），得分恰好是零。也就是说，这个在其他游戏上表现相当不错的算法，在这个游戏上一分都没拿到过，一无所成。于是它在 RL 社区成了一个“执念”：我们如何开发出能在这个游戏上取得进展的 AI 算法？




幻灯片 14：2013–2019 年 Montezuma's Revenge 得分进展——从 SARSA、DQN 家族的零分，到 RND 越过人类平均水平线。

前面说过，游戏是长时程任务的绝佳范例。于是围绕这个游戏开启了整整一个“探索时代”，历时近十年——按 AI 的标准，这是一段极其漫长的时间。无数团队尝试又失败，只为设计出能在这个游戏上做出点名堂的 AI 算法——按今天的眼光，它只是一个简单的探索类游戏。这张图上的每个点代表一个团队、一次（成功的）尝试；你可以想象，水面之下还有多少不愿发表的失败尝试。其中不少是基于前面提到的 DQN 的各种“加形容词”版本。

有个很有意思的点：比如 C51——仍然垫底、几乎零分——它其实是个非常有意思的新算法，开创了分布式强化学习（distributional RL）：不再只收集均值信号，而是收集整个回报分布。这个思路在许多任务上有效，但在这里依然不成功——尽管它如今有许多别的应用。还有 Rainbow，是 C51 打包了一大堆技巧的组合版，表现只比 C51 高一点点。IMPALA 是个很酷的东西——分布式 actor-critic 架构；到那会儿已经是 2018 年前后，A2C、A3C 都是流行的 RL 算法，IMPALA 相当于它们的“加强版”。

最后你会看到，终于有一个点越过了人类平均水平线——那就是随机网络蒸馏（RND，Random Network Distillation）。它终于在 Montezuma's Revenge 上超过了普通人类玩家——而这个游戏说白了很简单：在房间里走来走去、拿到钥匙、爬几段梯子……




幻灯片 15: Go-Explore 在 Montezuma's Revenge 上不仅超过人类平均水平，更超过人类专家水平。

.....走出房间，就这么点事。但对 AI 来说，这是一个意味深长的故事。再后来，出现了著名的 Go-Explore 算法，终于不仅超过人类平均水平，更是超过了人类专家水平。这说明人们前赴后继地尝试，而这事确实难——顾名思义，Go-Explore 的核心是“探索” (exploration)，但不是那种奖励“好奇心”、奖励“没见过的东西”的朴素探索——搜索空间巨大时，所有东西都是没见过的。真正的问题是：你究竟该如何收集到奖励？

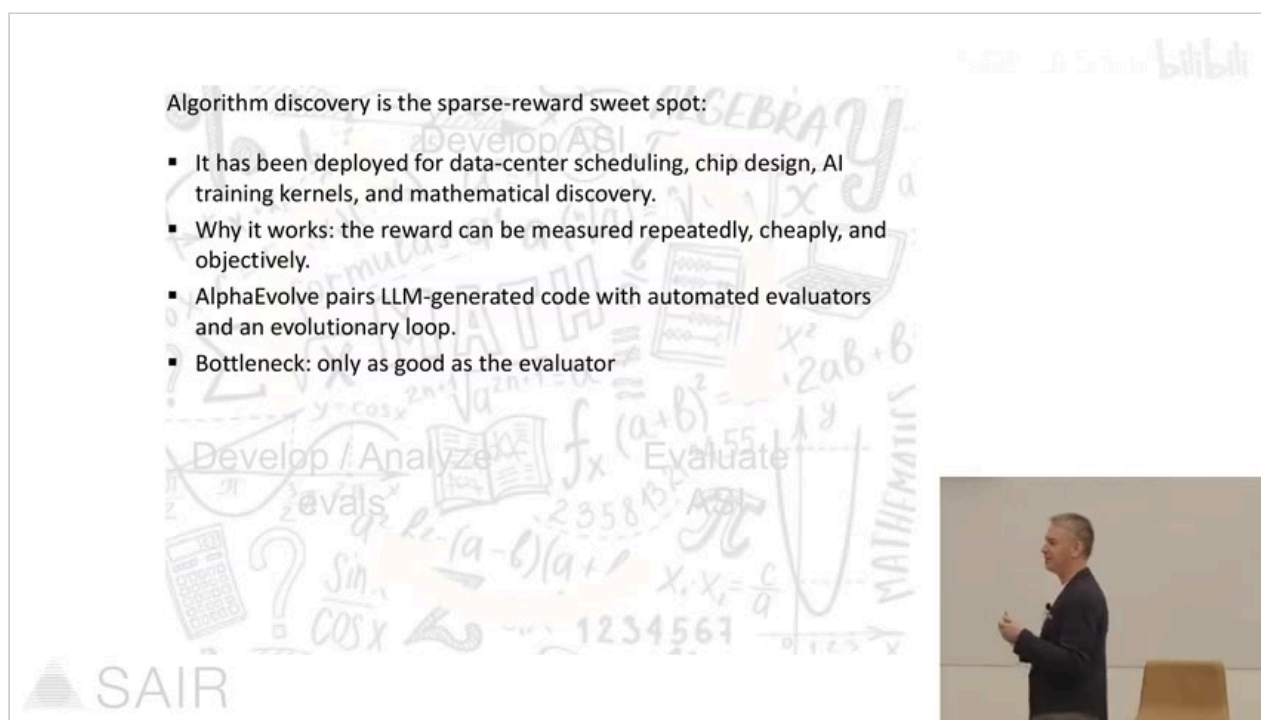
Go-Explore 的作者们想明白了这一点。它不是大量试错的简单产物——他们分析了此前每一次尝试失败的原因，识别出此前系统的两个关键缺陷：detachment（脱离）与 derailment（脱轨）——AI 在探索潜在候选时，会沿着一条很长的路径走很久，去验证这个搜索树分支是否有前途，但很多情况下它忘了自己需要回溯、需要重启。这正是之前的模型踩过的坑，而 Go-Explore 的作者意识到必须修复它们。

在我看来，这也很好地说明了攻克这类难题的真实过程。回到我之前提到的、David Eisenbud 带给我们的那个交换代数问题——我们的搜索过程一模一样：在真正有东西 work 之前，我们尝试了 50 种、甚至 100 种不同的算法和架构，超参数扫描就更不必提了.....



幻灯片 16：研究循环——开发 AI、开发/分析评估（evals）、评估 AI，循环往复。

.....这其实就是我们实验室的日常——我想这和任何 AI 研究实验室没什么不同：开发 AI、部署测试，然后最重要的环节是分析什么有效——对我们而言更多是分析什么无效，因为绝大多数尝试都不奏效。作为实验室主任，我的职责其实是鼓励每一个人：是的，我们应该再试一次；失败是默认选项、是预期之中；什么都不会一帆风顺，而我们的工作就是重复 50 次、有时 100 次，直到找到真正有效的那个。这就是我们的研究循环。



Algorithm discovery is the sparse-reward sweet spot:

- It has been deployed for data-center scheduling, chip design, AI training kernels, and mathematical discovery.
- Why it works: the reward can be measured repeatedly, cheaply, and objectively.
- AlphaEvolve pairs LLM-generated code with automated evaluators and an evolutionary loop.
- Bottleneck: only as good as the evaluator

Develop / Analyze / Evaluate

SAIR

幻灯片 17：算法发现是稀疏奖励的“甜区”——已部署于数据中心调度、芯片设计、AI 训练核、数学发现；奖励可被反复、廉价、客观地测量（AlphaEvolve = LLM 生成代码 + 自动评估器 + 进化循环）；瓶颈：评估器有多好，系统就有多好。

这张图说明的问题其实并不为我们所独有：凡是做算法发现（algorithm discovery）的 AI 都面临同样的处境——芯片设计、各种其他应用、我提过的自动驾驶，而在我们这里则是数学发现。你要找到一个能完成特定任务的算法。算法发现这类任务的好处在于：信号相当稳健，反馈回路相对健康；但问题往往出在评估器（evaluator）上——它能否判断你是否在朝正确方向前进，这常常是个挑战。已经有不少成功部署的系统，比如 AlphaEvolve，还有 AlphaTensor，等等。

但同样是稀疏奖励的问题——至少对我们来说——不仅出现在我们要解决的具体任务上，还出现在“寻找解决这个任务的方法”这件事本身上。这同样是个稀疏奖励问题：你必须尝试非常多的东西，才能看到那一丝信号——“哦，这个算法好像真的有点用”。所以这里有两个层级的稀疏性：一层在具体任务上，另一层在寻找方法本身上——“找方法”本身就是稀疏奖励问题，这也正是它在更广义的算法发现中的呈现方式。

Andrews-Curtis conjecture


- Statement of conjecture: every balanced presentation of the trivial group can be reduced to the trivial presentation via certain elementary transformations
- Unsolved problem in combinatorial group theory and algebraic topology, open for **60 years**
- Important in 3- and 4-manifold topology

L.Fagan, M.Tarquini, A.Shehper, M.Manko, A.Gruen, C.Huang, G.Butbaia, D.Passaro, S.G. (ICML 2026)

幻灯片 18：Andrews–Curtis 猜想——平凡群的所有平衡展示能否经若干初等变换化归为平凡展示；组合群论与代数拓扑中 60 年未解的问题，对 3、4 维流形拓扑意义重大（L. Fagan 等，ICML 2026）。

我要讲的最后一个问题，是另一个著名的数学大难题——Andrews–Curtis 猜想（Andrews–Curtis conjecture）。我们最近恰好通过前面说的这种试错与实验的过程，在它上面取得了进展。顺带说一句：我希望未来我自己甚至不需要在环路里——分析“哪里失败、如何改进”这个循环可以完全自主完成；但眼下，这仍然是个 AI 无法完全独立完成的稀疏奖励问题。

这个猜想来自群论（group theory），又一个数学分支。它问的是：平凡群（trivial group）的每一个所谓“平衡展示”（balanced presentation）——幻灯片顶部写了一个例子——能否通过若干种特定的变换（moves），连接到平凡群那个最无聊、最朴素的展示。允许的变换种类非常少，于是这变成一张抽象图上的搜索问题，而数学问题是：这张图是否连通——换句话说，从图上任意一点能否到达任意另一点。这个问题至今未解，而我们花了将近两年时间……



幻灯片 19：难度呈双峰分布——“容易/可解”（贪心启发式有效）与“不可能/困难”（超指数时程）之间缺失中间地带，而中间地带正是课程学习的目标。

.....才通过不断的实验弄明白：到底哪里出了问题？为什么这个问题对 AI 来说格外困难？

事情常常如此：对 AI 最重要的当然是数据。有句漂亮的俏皮话——garbage in, garbage out（垃圾进，垃圾出），你的模型顶多和你的数据一样好。而在这里，数据是合成的：至少在许多这类数学问题里，我们讨论的是抽象数学，可以通过合成过程轻松生成数据。但这里有一个我们当初没有意识到、数学上也无人知晓的问题——而这正是进展所在：数据的结构有毛病。你能合成出来的大量样本，都属于那“容易的一堆”，从中你学不到任何有意思的东西；而你真正想攻克的、数学上困难的潜在反例，却属于完全不同的另一堆，两堆之间什么都没有。一旦你在脑中看到这幅图景，你立刻就知道该怎么办、如何修正：你必须去填补这个“缺失的中间地带”(missing middle)，然后就能取得进展。于是最终，那篇论文也以几个定理收尾，.....

Why AC is Hard

Rubik's Cube	Andrews-Curtis
Single-player game	Single-player game
Many starting configurations, one goal state	Many starting configurations, one goal state
Superficially similar states can have very different difficulties	Superficially similar states can have very different difficulties
Every state is at most 20 steps away from goal state	States can be arbitrarily far apart, unknown if a path even exists
Easy to generate states of varying difficulty through random moves	Hard states are extremely rare, and unlikely to be reached through random moves
State difficulties are normally distributed	State difficulties have a "bimodal distribution," with easy states and potential counterexamples
Search problem on finite graph	Search problem on infinite graph

SAIR



幻灯片 20：Rubik's Cube 与 Andrews-Curtis 的对比——魔方：每个状态距目标至多 20 步、随机打乱即可生成各难度状态、难度正态分布、有限图搜索；AC：状态可任意远离目标、困难状态极稀缺、难度双峰分布、无限图搜索。

.....这些定理本身在数学上相当漂亮，但它们的得来方式，靠的是先搞清楚你的问题到底是什么。

前面说了，这个问题来自群论，而群论研究的是数学中的对称性。你几乎可以把群论里的每个问题都类比为某种版本的魔方（Rubik's Cube）——魔方也是关于对称性和非交换结构的。具体来说，这个猜想就像是某种“高配版”魔方——魔方本身对 AI 也是个有趣的游戏——只不过在魔方里，每一种状态都能连到目标状态（复原态），这是最理想的性质；而 AC 猜想相当于一个路径可以指数级、甚至超指数级长的“魔方”——事实上，猜想本身问的就是：是不是每个状态都能连到目标状态。

其次，在魔方上开始训练很容易：随便打乱（scrambling）就能得到不错的初始状态。但对我来说，那只能类比为“容易的那一堆”数据。如前一张幻灯片所示，这里的数据分布很不幸是双峰的——随机打乱产生不了好的初始状态。最后，魔方是在有限状态图上的搜索，而这里是在一张无限的、且没有显式给出的图上搜索。



- very different from games (problems) where agent can learn to fail quickly




SAIR

幻灯片 21：迷宫与魔方——这类问题与“智能体能快速试错、快速失败”的游戏截然不同。

所以这场演讲我想强调的点，总结一下就是：带有稀疏奖励和长时程的这类“游戏”，比通常的游戏——甚至包括国际象棋和围棋——要难得多。一盘国际象棋通常三四十步，一盘围棋最多几百上千步；但和这里的问题相比，这些都算又短又简单的游戏——在这里你得走上几百万、几十亿步，而走了几百万步之后，你仍然……

• generalization, OOD performance, robustness



• very different from games (problems) where agent can learn to fail quickly




SAIR



幻灯片 22：训练分布与泛化、分布外（OOD）表现、稳健性。


.....完全不知道自己走的到底是对是错。所以这是难得多的任务。而且我们立刻会撞上探索问题、也就是分布外泛化（OOD generalization）的问题：我们必须从极其微弱的信号中学会什么是有用的、什么是值得追的，要走到训练数据分布之外——不是超出 10%、30%，而是.....



幻灯片 23：训练分布的长尾——一般情形与极端情形相隔多个数量级。

.....许多、许多个“百万秒差距”（megaparsecs，形容距离之遥远）之外。而现有的模型——无论是 LLM 系还是 RL——在这件事上都做得不好。这些正是横亘在许多领域面前的障碍；我个人认为，它们也正是阻碍 AI 模型实现真正推理能力的问题。

我还提到过这个问题的另一面：这类稀疏奖励、微弱信号式的反馈，本质上就是大海捞针。它通常出现在数据分布极不均衡的时候——一般情形（generic case）与极端情形（extreme case）相隔遥远。国际象棋里，普通对局和最长对局之间只差一个数量级；而在这类问题里，极端情形与一般情形在复杂度、难度、奖励距离上可以相差许多个数量级。因此.....




幻灯片 24: Vladimir Arnold——“数学是物理学中实验廉价的那一部分”，此处改写为“数学是 AI 研究中实验廉价的那一部分”。

.....在一般情形上训练，对那些你真正关心的情形几乎教不会你任何东西。

我描述的问题——这是最后一张幻灯片——其实并不是数学特有的。没错，它经常出现在研究级数学里；但我真正在问的是：如何教会 AI 去大海里捞针、去寻找独角兽、去捕捉黑天鹅事件——那些概率极小、但重要性极高的事件。这类问题出现在极端天气、市场崩盘（“黑天鹅”一词正是借自那里）以及我前面提到的许多领域。而通过在数学问题上做这项研究，我们不需要任何来自医疗或金融系统的专有数据——我们可以研究抽象的数学问题、用合成数据来设计算法，但其效用有望广泛迁移到其他领域。

最后，我想改写著名数学家 Vladimir Arnold 的一句话。他说过：“数学是物理学的一部分，只不过在那里实验很便宜。”——我想他指的是大型对撞机那种耗资巨大的实验。那么请允许我改写为：“数学可以看作 AI 研究的一部分——在那里，我们既不需要昂贵的数据，也不需要昂贵的机器。”演讲就到这里，感谢各位聆听。



幻灯片 25：SAIR（The Foundation for Science and AI Research）结束页。

（视频在致谢画面中结束，无更多讲解内容。）